


3. Gün

3. Ders:

R'ye Giriş



Bulaşıcı hastalık dinamiklerinin R'de modellenmesi üzerine kısa kurs


Ankara, Türkiye, Eylül 2025

Dr Juan F Vesga

Oturumun amaçları

- Belirsizlik kaynaklarını anlamak
- Belirsizliği bildirmenin önemini anlamak
- Model belirsizliğini ele almaya yönelik temel yöntemleri öğrenmek

Problemin doğası





Ham veri: diğer çalışmalardan alınan insidans, serolojik veriler vb. veya parametre değerleri

Deterministik veya Stokastik


Sistemin özelliği veya istatistiği (Temas oranı, R_0 vb.)

Belirsizlik




Veri hatası

Stokastik veya
deterministik model



Sonuçtaki belirsizlik

Duyarlılık



Deterministik model için, iki tür:

- Yerel duyarlılık: parametrede bilinen değişiklik için sonuçta meydana gelen değişiklik.
- Global duyarlılık: sonuçtaki belirsizliğin herhangi bir girdi parametresinin belirsizliğiyle olan ilişkisi.

Parametre duyarlılığını gösterme modeli

Sonlu popülasyonda SIR tipi salgın, ör. İnfluenza, kızamık, kızamıkçık, Hepatit A.

Senaryo: I_0 enfektelerinin $N-I_0$ sayıda duyarlı bireyden oluşan popülasyona karışması.

$$\begin{aligned} S \rightarrow I & : \text{oran } \lambda = \frac{\beta I}{N} \text{ /gün,} \\ I \rightarrow R & : \text{oran } \mu \text{ /gün} \end{aligned}$$

$$R_0 = \beta / \mu$$

Parametre duyarlılığını gösterme modeli

Model aşağıdaki denklemler sistemiyle tanımlanabilir:

$$\frac{dS}{dt} = -\beta \frac{I}{N} S$$

$$\frac{dI}{dt} = \beta \frac{I}{N} S - \mu I$$

$$\frac{dR}{dt} = \mu I$$

$$R_0 = 2$$

$$I_0 = 100$$

Parametre duyarlılığını gösterme modeli



$$\frac{dS}{dt} = -\beta \frac{I}{N} S$$

$$\frac{dI}{dt} = \beta \frac{I}{N} S - \mu I$$

$$\frac{dR}{dt} = \mu I$$

$$R_0 = 2$$

$$I_0 = 100$$



Parametre duyarlılığını gösterme modeli



$$\frac{dS}{dt} = -\beta \frac{I}{N} S$$

$$\frac{dI}{dt} = \beta \frac{I}{N} S - \mu I$$

$$\frac{dR}{dt} = \mu I$$

$$R_0 = 1,5$$

$$I_0 = 100$$



Parametre duyarlılığını gösterme modeli



$$\frac{dS}{dt} = -\beta \frac{I}{N} S$$

$$\frac{dI}{dt} = \beta \frac{I}{N} S - \mu I$$

$$\frac{dR}{dt} = \mu I$$

$$R_0 = 2$$

$$I_0 = 10$$



Parametre duyarlılığını gösterme modeli

I_0 ve R_0 'a bağlı olduğundan salgın sırasında enfekte olan kişi sayısı (yani nihai boyut (f) veya atak hızı) ilgileniyoruz.

Deterministik model için,

$$1 - f = (1 - I_0 / N) \exp(-R_0 f)$$

Parametre duyarlılığını gösterme modeli

I_0 ve R_0 'a bağlı olduğundan salgın sırasında enfekte olan kişi sayısı (yani nihai boyut (f) veya atak hızı) ilgileniyoruz. Deterministik model için,

$$1 - f = (1 - I_0 / N) \exp(-R_0 f)$$

R_0 'daki varyasyona duyarlılık:

I_0	R_0	f
100	1,25	544
100	1,5	671
100	2	828
100	3	948
100	4	982

Parametre duyarlılığını gösterme modeli

I_0 ve R_0 'a bağlı olduğundan salgın sırasında enfekte olan kişi sayısı (yani nihai boyut (f) veya atak hızı) ilgileniyoruz. Deterministik model için,

$$1 - f = (1 - I_0 / N) \exp(-R_0 f)$$

I_0 'daki varyasyona duyarlılık:


I_0	R_0	f
1	2	797
10	2	800
100	2	828
200	2	855
300	2	879

Yerel belirsizlik


- Parametreler tek tek değiştirildiğinden yerel duyarlılık ilgili sonuçtaki değişime bakar.
- Modelimizde nihai boyut üreme sayısına (R_0) ve başlangıçtaki enfekte bireylere (I_0) bağlıdır.

$R_0=2$, $I_0=100$ olduğundaki duyarlılığa bakabiliriz.

$$R_0 = 2$$



$$I_0 = 100$$




Farklı parametrelerin *birleşerek* sonucu nasıl etkilediğini bize göstermez.

Latin Hiperküp Örnekleme

- Değerlendirme masraflıysa tüm değerleri gözden geçirmeyi istemeyin.
- LHC, bölgeyi 'kapsayan' noktaların alt kümesini seçme yöntemidir.

Önceki örnekten:



1						X			
2							X		
3			X						
4	X								
5					X				
6				X					
7									X
8		X							
9								X	
10					X				
	R_{01}	R_{02}	R_{03}	R_{04}				

R_0

10X10 küp: ortalama = 780, ss. = 86

- Her bir parametre değeri yalnızca bir kez görünür.
- Daha fazla set elde etmek için işlemi tekrarlayabilir.

Monte Carlo Markov Zinciri


- MCMC dağılımdan gelmiş gibi görünen parametre setleri dizisi üretmenin bir yoludur.
- Kural gereği adı üzerinde 'zincir' olduğundan her eni set önceki setten üretilir.

$$(x_1, x_2)_n \Rightarrow (x_1, x_2)_{n+1}$$

Metropolis Algoritması

Öncelikle, rastgele bir şekilde eskisinden yeni bir parametre seti seçmenin yolunu oluşturur. (simetrik olmalıdır. Ör. her birine normal sapma eklenir).

- Son noktadan (x_1, x_2) yeni bir nokta oluşturur (x_1^*, x_2^*)
- A'yı hesaplar, burada $A = p(x_1^*, x_2^*) / p(x_2, x_2)$
- $[0,1]$ arasında rastgele bir sayı (u) alır.
- $u < A$ ise yeni noktayı kabul eder. Değilse eskisini yeniden ku

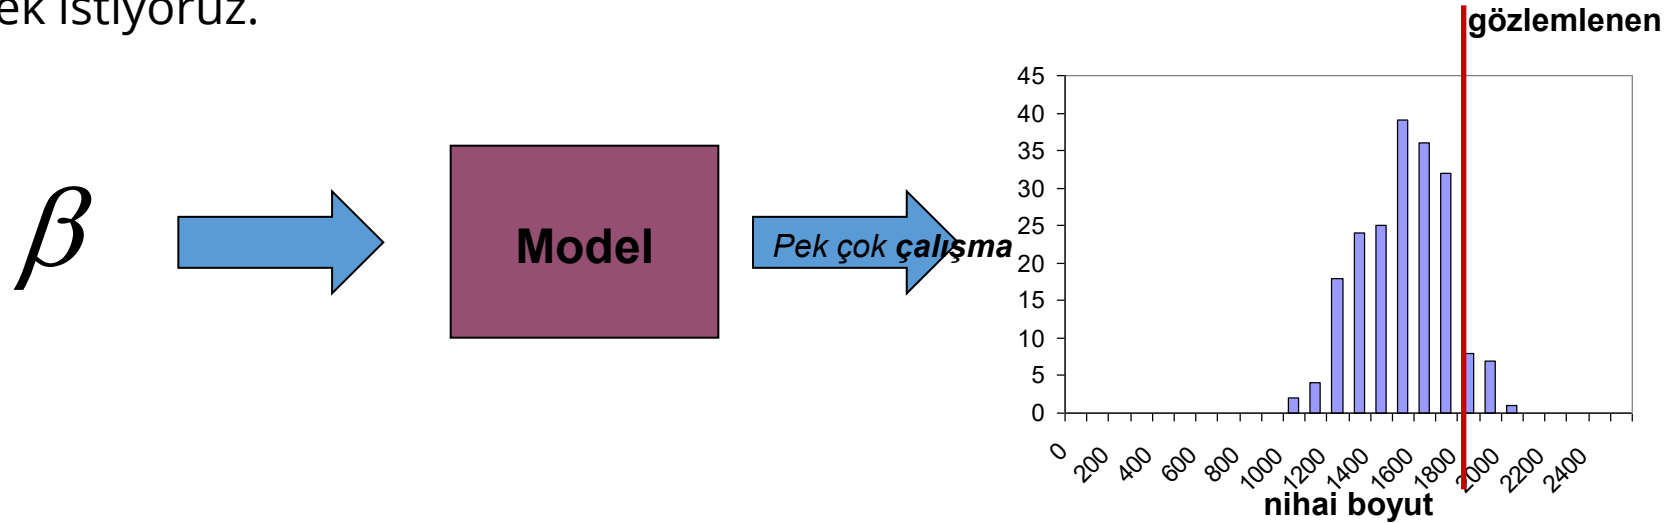


Not: ardışık noktalar bağımsız değildir!

Stokastik ve olasılık modelleri: olabilirlik

- Stokastik modeller, temsil ettikleri süreçlerin rastgeleliğini içerir, ör. enfeksiyon, iyileşme, ölüm, vb.
- Bu yüzden modelin her çalışması aynı parametrelerden farklı sonuçlar verecektir.

Bir salgın modelini düşünün: β değerlerinin gözlemlenen nihai salgın boyutunu verdiğini bilmek istiyoruz.



Sorular:

- β için 'en iyi' değer nedir?
- Hangi β değeri aralığı kabul edilebilir?


Olabilirlik

Verilerin olabilirliği,
verilen parametreler


=

Gözlemlenen verilerin parametreler göz önünde bulundurularak
model tarafından oluşturulma olasılığı

β




Pek çok çalışı



β 'lerin aralığı için tekrar ederek,
 β 'ye karşılık olasılık
grafiği oluşturabiliriz.

Pik değer 'en iyi' değeri gösterir, buna
maksimum olabilirlik tahmini (MLE) denir.




Log-Olabilirlik ve güven aralıkları

Olabilirlik eğrisinin log'unun şekli bize uygun b değerlerinin aralığını verir.

Eğrinin tepesinden Q'ya kadar ölçersek

$$Q = \frac{1}{2} \chi_{0.05}^2(n)$$

Bu, parametre değerleri için %95 güven değerini tanımlar.



Verilerden kaynaklanan belirsizlik

Sıtma antijeni için seropozitif oranını tahmin etmek için bir popülasyondan örnek almayı düşünün. Şunu varsayın:

Örneklenen bireyler = **N**


Seropozitif bireyler = **k**

p seropozitif oranını tahmin etme ihtiyacı.


Binom olabilirlik fonksiyonu kullanırız:

$$L = \binom{N}{k} p^k (1-p)^{N-k}$$

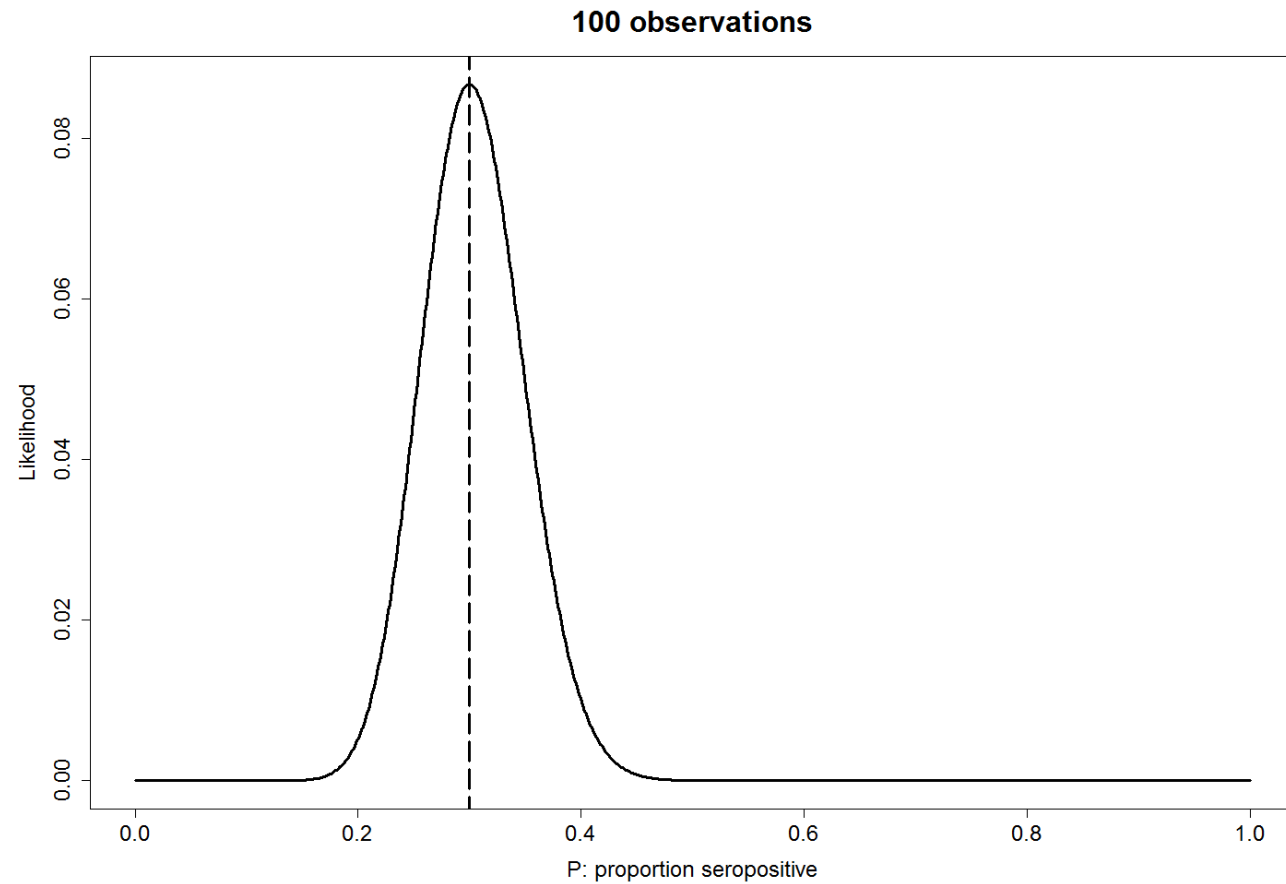
Verilerden kaynaklanan belirsizlik




Verilerden kaynaklanan belirsizlik




Verilerden kaynaklanan belirsizlik



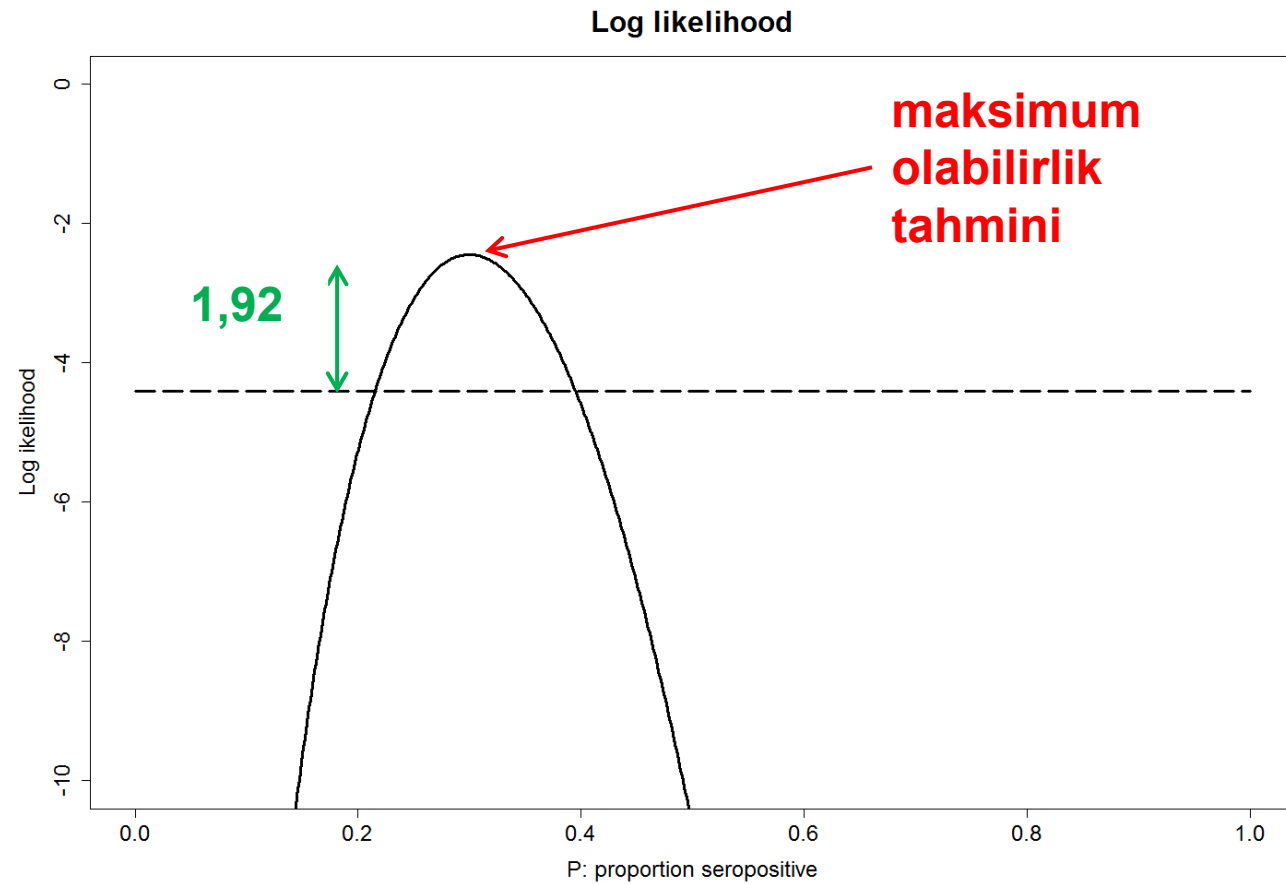
Verilerden kaynaklanan belirsizlik




Verilerden kaynaklanan belirsizlik



Verilerden kaynaklanan belirsizlik



Verilerden kaynaklanan belirsizlik



Verilerden kaynaklanan belirsizlik

Genel olarak:

- daha fazla veri \Rightarrow daha az belirsizlik
- daha fazla veri \Rightarrow daha dar güven aralıkları

Model seçimine bağlı olabilir, örneğin model kötü seçilmişse verilerin çok olması da bir işe yaramayacaktır.

Özet

- Olası parametre değerlerini bulmanın yolları incelendi
- Sonuç değişkenlerinin dağılım ve duyarlılığı tahmin edildi.
- Analiz için parametre seti oluşturmak amacıyla kullanılan bir diğer yöntem
- Monte Carlo Markov Zincir algoritmalarıdır. Çok basit ve yaygın kullanılan sağlam bir algoritmadır.
- Olabilirlik yöntemleri, gözlemlenen verilere karşılık gelen parametre aralıklarını bulmak için oldukça faydalıdır.
- Veri setleri karmaşık hale geldikçe (ör. insidans eğrileri) olabilirliğin hesaplanması da zorlaşmaktadır.
- Elinizde ne kadar çok veri olursa parametre tahmininiz de o kadar doğru olur.
- Model iyi değilse en iyi uyumu elde etmeniz mümkündür bu yüzden saçma olduğunu düşünmeyin.